

МЕТОДОЛОГИЧЕСКИЙ ОТЧЕТ

Выявление экономической структуры российских муниципалитетов с использованием кластеризации на атрибутированных сетях

Финальная конфигурация: *Louvain resolution = 1.25*
Период: январь 2023 - декабрь 2024

Аннотация

Работа рассматривает муниципалитеты как узлы динамической атрибутированной экономической сети. Атрибутами узлов служат доли потребительских расходов по пяти категориям, а ребро между муниципалитетами отражает близость их экономических профилей. Для каждого месяца строится взвешенная kNN-сеть, после чего сообщества выявляются методом Louvain. Месячные сообщества затем описываются через экономические профили и объединяются в три устойчивых экономических типа. Финальная конфигурация использует Euclidean distance, $k = 10$, RBF-вес и $resolution = 1.25$.

1. Постановка задачи

Задача проекта – получить интерпретируемую динамическую типологию муниципалитетов, которая одновременно учитывает экономические характеристики муниципалитетов и их близость друг к другу. Такой подход позволяет и разделить муниципалитеты на группы, и наблюдать изменения структуры групп во времени.

2. Данные и объект анализа

Основной источник – муниципальные данные СберИндекса по потребительским безналичным расходам. Набор `consumption.parquet` охватывает период с января 2023 года по декабрь 2024 года включительно. В исходном наборе представлены около 2 тыс. муниципальных образований, а в подготовленной панели получено 50 521 наблюдение `municipality-month` за 24 месяца.

Признак	Содержание	Роль
Продовольствие	Расходы на продукты питания для домашнего приготовления и потребления	Основной атрибут
Здоровье	Лекарства, медицинские изделия и услуги	Основной атрибут
Маркетплейсы	Транзакции на онлайн-платформах с множеством продавцов	Основной атрибут
Общественное питание	Рестораны, кафе, fast food и доставка готовой еды	Основной атрибут

Транспорт	Общественный транспорт, такси, каршеринг, топливо, обслуживание и доставка	Основной атрибут
market_access	Относительный потенциал доступного внешнего рынка в 2024 году	Дополнительная интерпретация

Источник данных: описание муниципального набора СберИндекса. Набор также содержит индекс доступности рынков и транспортные связи между муниципалитетами; в текущей конфигурации они не входят в основной атрибутный вектор и не используются для построения ребер, а рассматриваются как потенциальный контекст для интерпретации результатов.

3. Формирование атрибутов

Для каждого municipality-month исходные расходы преобразуются в структуру пяти выбранных категорий. Основными атрибутами модели являются доли food_share, health_share, marketplaces_share, catering_share и transport_share. Их сумма равна единице с учетом вычислительной погрешности. Такое представление переводит анализ от абсолютного масштаба расходов к относительной структуре потребительского поведения.

4. Построение экономической сети

Каждый муниципалитет становится узлом. Для каждого месяца рассчитывается Euclidean distance между пятимерными векторами долей. Для каждого узла выбираются $k = 10$ ближайших соседей. Затем направленные связи симметризуются и превращаются в неориентированный взвешенный граф.

Вес ребра определяется RBF-функцией:

$$w_{ij} = \exp(-d_{ij} / \sigma)$$

Здесь d_{ij} – евклидово расстояние между экономическими профилями, а σ – для каждого месяца рассчитывается как медиана всех расстояний до 10 ближайших соседей в этом месяце. В результате муниципалитеты с близкими структурами потребления получают более сильную связь.

5. Динамическая кластеризация

Сеть строится отдельно для каждого месяца в периоде 2023-01 - 2024-12. Для каждого графа применяется Louvain с фиксированными $seed = 42$ и $resolution = 1.25$. Полученные номера кластеров являются локальными для месяца и не трактуются как постоянные типы: номер 0 в одном месяце не обязан соответствовать номеру 0 в другом месяце.

6. Выделение устойчивых экономических типов

Для каждого месячного кластера рассчитывается экономический профиль - средние значения пяти долей. Затем профили кластеров объединяются методом KMeans с учетом размера месячного кластера как веса. Финальная модель использует $K = 3$ (по результатам проверки $K = 3 \dots 10$: для трех типов одновременно достигаются максимальные значения Silhouette, взвешенного Silhouette и Calinski-Harabasz среди проверенных вариантов).

7. Финальные экономические типы

Тип	Продовольствие	Здоровье	Маркетплейсы	Общепит	Транспорт
Маркетплейсно-ориентированный	60.0%	6.4%	23.0%	3.3%	7.2%
Диверсифицированный сервисный	50.3%	8.4%	19.8%	10.4%	11.1%
Продовольственный	67.9%	6.5%	14.2%	3.5%	7.8%

Названия типов являются описательной интерпретацией профилей. Они не являются официальной классификацией муниципалитетов.

8. Выбор финальной конфигурации

Resolution = 1.25 выбрано после серии проверок разных resolution, атрибутивных и сетевых показателей качества и анализа устойчивости к изменению seed. Дополнительно сравнивались Euclidean и Cosine distance при контролируемой одинаковой схеме kNN и RBF-взвешивания.

Метод	Resolution	Кластеров	Modularity	SW	CH	S_Dbw
Euclidean	1.25	20	0.8145	0.1636	879.1	0.3210
Cosine	1.25	30	0.8129	0.1555	698.2	0.3022

Сравнение показывает различный баланс показателей: Euclidean дает выше Modularity, Silhouette и CH, тогда как Cosine имеет более низкий S_Dbw. Поэтому выбор Euclidean основан на совокупности сетевых и атрибутивных диагностик, а также на последующей интерпретируемости типов.

Для всех 50 521 общих наблюдений точное совпадение присвоенных семантических меток с предыдущей конфигурацией составляет 95.85%; ARI между типологиями равен 0.8723.

Метрика	Значение
Silhouette (SW)	0.1636
Calinski-Harabasz (CH)	879.10
S_Dbw	0.3210
AVI	0.8794
AVU	0.4813
MQ	17.5880

Modularity	0.8145
Средний попарный ARI для 5 seed	0.6856

Для Silhouette, CH, AVI и MQ большие значения соответствуют лучшему значению показателя; для S_Dbw и AVU – меньшие. Показатели используются совместно. AVI, AVU и MQ в проекте используются как сетевые диагностические показатели внутренней и внешней связности кластеров.

9. Оценка финальной типологии

Показатель	Значение
Silhouette	0.3456
Calinski-Harabasz	38 527.26
Наблюдений	50 521
Устойчивых экономических типов	3
Louvain resolution	1.25

10. Временная интерпретация

Динамическая часть проекта позволяет отслеживать, как меняются локальные сообщества и доли устойчивых экономических типов по месяцам. Для соседних месяцев рассчитываются переходы муниципалитетов между типами; эти переходы могут быть представлены матрицей потоков и Sankey-диаграммой.

11. Ограничения

- Пять признаков описывают структуру выбранных категорий потребления, а не всю экономическую деятельность муниципалитета.
- market_access является статическим показателем 2024 года и не входит в основной атрибутный вектор.
- Внутримесячные Louvain-кластеры не имеют автоматически постоянных идентификаторов во времени.
- ICVI зависят от K и структуры данных, поэтому используются совместно.
- Экономические названия типов являются интерпретацией результата модели.

12. Воспроизводимость

В репозитории зафиксированы параметры в configs/config.json и последовательность из 15 ноутбуков. Для полного воспроизведения пайплайна следует последовательно выполнить ноутбуки 01-15. При наличии уже сохраненных промежуточных результатов из data/processed финальная оценка и визуализация могут быть повторно получены запуском ноутбуков 12-15. Зависимости перечислены в requirements.txt.

13. Источник данных

СберИндекс. Потребительские безналичные расходы на уровне муниципальных образований по категориям трат; индекс доступности рынков; транспортные связи между муниципальными образованиями. Описание набора:

<https://sberindex.ru/ru/research/data-sense-opisanie-nabora-dannikh-khakatona-sberindeksa-po-munitsipalnim-dannim>