

ЭКОНОМИЧЕСКАЯ СТРУКТУРА МУНИЦИПАЛИТЕТОВ

Динамическая кластеризация на атрибутированных сетях

Как из структуры потребительских расходов получить
устойчивую типологию муниципалитетов

СберИндекс


2023-01 - 2024-12

3 экономических типа

Финальная модель

Euclidean + kNN(10) + RBF + Louvain(1.25)

Методологический конкурсный проект




Задача и идея

Почему здесь нужна именно атрибутированная сеть

Обычная кластеризация

смотрит на признаки муниципалитета как на отдельный вектор.



Признаки

food

health

market

Наша постановка

**Муниципалитет = узел
экономической сети**

Атрибуты узла – структура потребительских расходов.

Ребро – экономическая близость профилей.

Одновременно анализируем

атрибуты

связи

динамику

Результат – не только группы, но и наблюдаемая во времени типология локальных экономик.

Данные и признаки

Панель municipality-month за 24 месяца

Наблюдений

50 521

municipality-month

Период

24 мес.

янв. 2023 - дек. 2024


Основных признаков

5

доли категорий

- Продовольствие
- Здоровье
- Маркетплейсы
- Общественное питание
- Транспорт

Доли пяти выбранных категорий суммируются до 1 с учетом округления.



market_access и транспортные связи используются как контекст, но не входят в основной пятимерный вектор признаков.

Источник данных: СберИндекс. Лицензия набора данных – CC BY-SA 4.0.

Как строится экономическая сеть

Один и тот же принцип применяется для каждого месяца



Почему kNN?

Сеть остается разреженной и интерпретируемой: каждый муниципалитет соединен только с ближайшими экономическими профилями.

Динамическая часть

Почему месячные кластеры нельзя просто «склеить» по номеру



1 / Ежемесячная сеть

24 графа строятся независимо для месяцев 2023-2024.

2 / Локальные сообщества

Номера Louvain-кластеров не являются постоянными типами.

3 / Устойчивые типы



Профили месячных кластеров объединяются в $K = 3$ экономических типа.

«номер 0» ≠ постоянный тип

Так сохраняется содержательный смысл динамики:
мы отслеживаем изменение экономической структуры, а не идентификаторов кластеров.

Как выбрали resolution = 1.25

Решение принято по совокупности сетевых, атрибутивных и устойчивых проверок



Что показали проверки?

- ICVI** 1.25 дает сбалансированный профиль показателей, без опоры на один индекс.
- Стабильность** Средний попарный ARI для 5 seed при 1.25 = 0.6856.
- Расстояние** Euclidean при 1.25 выше Cosine по Modularity, SW и CH.

Подсветка на графиках = выбранная точка 1.25.

Финальная resolution = 1.25

Не максимум одной метрики, а выбранный компромисс между качеством и устойчивостью.

ICVI и устойчивость финальной конфигурации

Декабрь 2024, resolution = 1.25

Silhouette (SW)

0.1636

выше – лучше

Calinski–Harabasz (CH)

879.10

выше – лучше

S_Dbw

0.3210

ниже – лучше

AVI

0.8794

выше – лучше

AVU

0.4813

ниже – лучше

MQ

17.5880

выше – лучше

Modularity

0.8145

сетевое качество

Средний попарный
ARI

0.6856

5 seed

Интерпретация

SW, CH, AVI и MQ читаются в сторону больших значений; для S_Dbw и AVU – наоборот. Метрики используются совместно, поскольку каждая описывает свою сторону структуры кластеров.

AVI, AVU и MQ в проекте используются как реализованные сетевые диагностические показатели внутренней и внешней связности кластеров.

Euclidean vs Cosine

Контролируемое сравнение: одинаковый kNN, одинаковый RBF, resolution = 1.25

Метод	Кластеров	Modularity	SW	CH	S_Dbw
Euclidean	20	0.8145	0.1636	879.1	0.3210
Cosine	30	0.8129	0.1555	698.2	0.3022

Что меняется?

Euclidean дает более высокие Modularity, SW и CH.
Cosine дает более низкий S_Dbw.
Поэтому выбор – это баланс показателей, а не победитель по одному индексу.


Почему остаемся на Euclidean

Он лучше поддерживает сетевую структуру при контролируемом сравнении и остается прозрачным для интерпретации «насколько близки две композиции потребления».

Контрольный срез: декабрь 2024. Для Cosine использована отдельная глобальная sigma как контролируемая схема сравнения.

Три устойчивых экономических типа

Интерпретация строится по профилям пяти долей



Названия типов – описательная интерпретация результата модели, а не официальная классификация.

Маркетплейсно-ориентированный

~23% маркетплейсов; около 60% продовольствия

Диверсифицированный сервисный

выше общепит и транспорт; ниже продовольственная доля


Продовольственный

~68% продовольствия и самая низкая доля маркетплейсов

K = 3: лучший профиль по K=3...10

Как меняется структура типов во времени

Доли municipality-month наблюдений по устойчивым экономическим типам



Что видно на панели

Структура типов меняется по месяцам: в 2023 году продовольственный тип занимает заметную долю панели, а в 2024 году возрастает доля маркетплейсно-ориентированного типа.


Ян. 23 → Дек. 24

Эта динамика – один из основных результатов именно сетевого и временного подхода.

Источник:
monthly_economic_type_shares_final_125.csv

Переходы муниципалитетов между типами

Сумма 23 последовательных месячных переходов: январь 2023 → декабрь 2024



Sankey агрегирует переходы между соседними месяцами; это поток переходов, а не число уникальных муниципалитетов.

Источник: economic_type_transitions_final_125.csv

Финальная оценка

Итог по 50 521 municipality-month наблюдению

Silhouette

0.3456

финальная типология,
K = 3

Calinski-Harabasz

38 527.26

на всей панели

ARI vs 1.50

0.8723

согласованность
типологий

Exact match rate

95.85%

семантических меток

Финальная конфигурация

resolution 1.25

k = 10

seed = 42

K = 3

Euclidean + RBF

Контрольный срез декабрь 2024: 20 Louvain-кластеров и Modularity = 0.8145.

Воспроизводимость и ограничения

Проект рассчитан на повторный запуск из репозитория

Воспроизводимость

- 01 **config.json** финальные параметры модели
- 02 **01 → 15** полный исследовательский pipeline
- 03 **data/processed** сохраненные промежуточные результаты
- 04 **outputs/figures** готовые визуализации

RUN_ME_FIRST.md + README.md

Ограничения

- Пять признаков описывают выбранную структуру потребления, а не всю экономику муниципалитета.
- market_access – статический показатель 2024 года и не входит в основной вектор.
- Месячные Louvain-кластеры не имеют постоянных идентификаторов сами по себе.
- Названия трех типов – интерпретация профилей, а не официальная классификация.

Итог

Мы построили динамическую атрибутивную сеть, где экономическая близость муниципалитетов становится частью модели.



01 Сеть

24 ежемесячных
графа
на основе kNN + RBF

02 Типология

3 устойчивых
экономических
типа

03 Динамика

изменение структуры
наблюдается во
времени

Финальная модель: Euclidean + kNN(10) + RBF + Louvain(1.25)

Silhouette = 0.3456

ARI vs 1.50 = 0.8723

3 устойчивых типа